

顾仁杰

☎ 15261627442 ✉ jackyofgrj@gmail.com 🏠 <https://csujc.github.io/renjie123.github.io/>

🎓 教育经历

- | | |
|---------------------------------------|-------------------|
| 复旦大学NLP实验室 | 2026.09 – 2029.06 |
| 先进制造与智能机器人学院 计算机科学与技术专业-多模态大模型与具身智能方向 | 导师: 曹艺馨 |
| 中南大学 | 2022.08 – 2026.06 |
| 计算机学院 计算机科学与技术专业 | |
- 总GPA: 3.93/4.0; 学分加权均分: 91.27; 专业综合成绩排名 10/268;
 - 部分专业核心课程成绩: 高等数学 (97), 概率论 (98), 计算机组成原理与汇编 (98), 离散数学 (94), 算法 (95), 编译原理(94), 数据库 (97), 人工智能 (94), 电路理论 (95), 数字电子技术 (90), 大学物理(97)

📄 学术成果 (†代表共同第一作者)

- [On submission] Renjie Gu, Jiaxu Li, et al. “Bridging the Detection-to-Abstention Gap in Reasoning Models under Insufficient Information”, NeurIPS 2026
- [On submission] Renjie Gu†, Kaichen Zhou†, Yan Luo, Mengyu Wang. “GeoWorld-VLM: Geometry from World Models for Vision-Language Models”, NeurIPS 2026 & FMEA @ CVPR 2026 Poster
- [On submission] Yihao Wang, Haoran Xu, Renjie Gu, et al. “MedMemoryBench: Benchmarking Agent Memory in Personalized Healthcare”, NeurIPS 2026
- [Accepted] Renjie Gu, Jiazhen Du, et al. “Unlearners Can Lie: Evaluating and Improving “Honesty” in LLM Unlearning”, ACL 2026 Main & NeurIPS 2025 Lock-LLM Workshop
- [Accepted] Boheng Li, Renjie Gu, et al. “Towards Resilient Safety-driven Unlearning for Diffusion Models against Downstream Fine-tuning”, NeurIPS 2025
- [Accepted] Yishuo Cai†, Renjie Gu†, et al. “MHALO: Evaluating MLLMs as Fine-grained Hallucination Detectors”, ACL 2025 Findings
- [Accepted] Rongwu Xu, Yishuo Cai, Zhenhong Zhou, Renjie Gu, et al. “Course-Correction: Safety Alignment Using Synthetic Preferences”, EMNLP 2024

🔧 科研/实习经历

- | | |
|------------------------|--------------|
| 字节跳动 Tiktok Shop 基座模型组 | 2026.7 – Now |
| 研究型实习生 | 导师: Zejun Li |
- 探索通过OPSD和RL提升MLLM agent的感知能力, 以及Crop工具调用能力, which is for better and efficient perception.使用Verl框架。正在完成一篇一作论文, 投稿至ICLR 2027.
- | | |
|----------------|------------------|
| 蚂蚁集团蚂蚁研究院和蚂蚁健康 | 2025.12 – 2026.7 |
| 研究型实习生 | 导师: Yun Yue |
- 提出了Judge-then-solve推理范式, 通过SFT和强化学习来提升large reasoning model对于条件缺失问题的拒答率和效率。过程中我实现了全链路的微调数据构造, 强化学习损失函数设计, Slime框架调试。已产出一篇一作论文, 投稿至Neurips 2026.
- | | |
|--------------------|-----------------------|
| 哈佛大学AI和Robotics实验室 | 2025.5 – 2026.12 |
| MLLM空间推理 科研实习生 | 导师: Prof. Mengyu Wang |
- 提出了利用世界模型 (Lingbot-world-fast) 中空间表征对齐MLLM, 帮助其进行空间推理任务的方法。已产出一篇一作论文, 投稿至Neurips 2026.
 - 尝试结合Non-linear的速度来改进Redicted flow, 提高图像生成质量, 但是没有work.

密歇根州立大学OPTML实验室
可信人工智能与大模型遗忘 暑期实习生

2025.05 – 2025.10
导师: Prof. Sijia Liu

- 参加了OPTML实验室的暑研，研究LLM unlearning，针对现有评估方法的不足和遗忘方法的遗忘质量改进展开研究，提出了LLM unlearning的honesty的评测标准，并且从表征层面进行对齐训练，实现了更honest的unlearning。已产出一篇一作论文，被ACL 2026 MAIN和NeurIPS 2025 Lock-LLM workshop接收.

南洋理工大学
AI安全与可信机器学习方向 科研助理

2024.12 – 2025.06
导师: 张天威副教授, 李一鸣研究员

- 研究文生图扩散模型的概念擦除，期间提出了对下游微调更鲁棒的unlearning方法。我调研并总结了现有文生图概念擦除的方法，将其建模为双层优化问题，在senior phd 李勃衡的指导下，借鉴Meta Learning精准高效的估计梯度，实现了全部代码。已被NeurIPS 2025接收，我为该论文的第二作者。

对于多模态大模型作为裁判进行幻觉标注的研究

2024.11 – 2025.03
指导老师: 黄民烈教授

- 聚焦于MLLM在细粒度幻觉检测能力评估。我们构造了用于评估模型幻觉标注能力的benchmark，提出了与人类偏好对齐的Metric，并且对caption, reasoning等test-time scaling等方法对于模型Judge能力的提升进行了探究，最后使用SFT进行微调。该工作被 ACL 2025 Findings 接收。

从Course-correction出发的大语言模型安全对齐研究

2024.05 – 2025.08
指导老师: 邱寒副教授

- 研究LLM的安全对齐。我们发现llm面对危险提示词会在中间自我纠正,我们对于这一现象建立了benchmark并且构造数据集，使用DPO算法微调模型，提升了安全对齐程度。该工作被 EMNLP 2024 Industry Track 接收。

早期实习项目及个人项目

2023.07 – 2023.09

- 在北京心芯相栖科技实习期间，参与开发“小猫希拉”——基于 LLM 的 iOS 陪伴应用，主要负责 iOS 客户端开发、LLM 应用接入及 Agent workflow构建，探索大语言模型在陪伴式交互场景中的产品化落地。
- 独立开发多个 LLM Agent 原型项目，包括结合 Notion 的 AI 私人秘书、本地语音交互 AI及旅游规划 Agent。其中，旅游规划 Agent 采用“目的地认知生成—用户兴趣选择一个个性化行程规划”的多阶段交互流程，先生成目的地的人文、自然景观、休闲娱乐等候选体验维度，再基于用户选择生成定制化旅行路线。

♥ 获奖情况（部分）

国家级优秀项目，大学生创新创业大赛

2024.05

全国二等奖，全国大学生英语竞赛

2022.05

🔧 荣誉与奖学金（部分）

- 奖学金：山茶花奖学金（全院仅2人获得）、中南大学一等学年奖学金（院内前5%）
- 荣誉：高中时获得泮池之星荣誉，全年级仅3人获得

⚙️ 专业技能

- 编程语言与技术栈: Python (Numpy, Pandas, PyTorch,llama-factory,Slime), Swift
- 基础技能: Git, L^AT_EX, VS Code, SSH, Codex,Claude code.
- 语言: 大学英语四级602，六级519，雅思7.0

i 关于我，你还会想知道...

- 研究兴趣广泛，包括LLM的对齐，以及从表征/注意力层面进行研究。我对于LLM的应用，例如deep research, MLLM agent也很感兴趣；同时我对于多模态大模型相关的Topic，包括MLLM的理解, Unified MLLM, World model也很感兴趣，这将会是我下一个阶段的研究重点。

- 本人对人工智能技术(llm, mllm, diffusion model等)有极大的热情,平时喜欢阅读感兴趣的论文和博客,自学过李宏毅老师,李沐老师,以及Stanfoerd的CS 231n, CS336等网课。也热衷将技术用于解决实际问题,开发自己的小项目(ai语音助手, ai秘书等)和ios app。
- 本人热爱交流、享受团队合作、乐于助人,性格开朗大方,做事踏实负责,热爱运动,喜欢撸铁、羽毛球、跑步、游泳;也很喜欢读书,看电影,旅游。
- 人生观:纵有千古,横有八荒,我希望增加生命的体验和厚度;同时,我也想好好参与进AI研究这个我感兴趣也有意义同时能让我有经济基础探索其他东西的事业,做出Solid的工作。